

How much is too much

Mirna Tetzner

February 2025

1 Modelagem da Probabilidade de Ausência Baseada na Idade da Mãe

1.1 Fundamentação Estatística: Probabilidade de Ausência

O objetivo é modelar a probabilidade condicional de ausência da variável IDADEPAI com base na IDADEMAE. Isso significa que, à medida que a idade da mãe diminui, a probabilidade de ausência do dado aumenta.

Formalmente, queremos modelar a seguinte probabilidade condicional:

$$P(\text{IDADEPAI ausente} \mid \text{IDADEMAE})$$

1.2 Função Logística

Uma forma comum de modelar essa relação é por meio da função logística:

$$P(\text{IDADEPAI ausente}) = \frac{1}{1 + e^{-\beta(\text{IDADEMAE} - \mu)}}$$

onde:

- β controla a taxa de variação da probabilidade.
- μ representa a idade média das mães na população.
- e é a base do logaritmo natural (aproximadamente 2.718).

A função logística é útil porque:

1. Gera probabilidades no intervalo $[0,1]$.
2. Modela efeitos suaves: a transição da ausência para a presença ocorre de maneira gradual.
3. É amplamente utilizada em modelos de regressão logística.

No código em R, isso pode ser representado por:

```
dt_simulado[, prob_missing := 1 / (1 + exp(0.3 * (IDADEMAE - mean(IDADEMAE, na.rm = TRUE))))]
```

2 Interpretação do Modelo

Se representarmos graficamente essa função logística, podemos observar que:

- Mães mais jovens têm maior probabilidade de ausência de IDADEPAI.
- Se IDADEMAE for muito abaixo da média, $P(\text{missing})$ tende a 1.
- Se IDADEMAE for acima da média, $P(\text{missing})$ tende a 0.

A tabela a seguir mostra a variação da probabilidade de ausência para diferentes valores de β :

IDADEMAE	$\beta = 0.1$ (suave)	$\beta = 0.3$ (médio)	$\beta = 0.5$ (íngreme)
18 anos	80% missing	90% missing	95% missing
25 anos	50% missing	60% missing	75% missing
35 anos	10% missing	20% missing	40% missing

Table 1: Variação da probabilidade de ausência conforme IDADEMAE e β

A escolha do coeficiente β afeta a rapidez com que a transição ocorre:

- Se β for pequeno (0.1), a mudança de probabilidade é suave.
- Se β for grande (0.5), a mudança é mais abrupta.

3 Relação com Modelos Estatísticos

Esse modelo se baseia em duas abordagens estatísticas:

3.1 Regressão Logística

A regressão logística é um modelo amplamente usado para modelar variáveis binárias. A forma geral do modelo logit é:

$$\log \left(\frac{P(Y = 1)}{1 - P(Y = 1)} \right) = \beta_0 + \beta_1 X$$

onde Y é a variável indicadora da ausência de IDADEPAI e $X = \text{IDADEMAE}$.

3.2 Modelos de Risco Proporcional

Outra abordagem possível é o modelo de risco proporcional de Cox, amplamente usado em análise de sobrevivência. A função logística pode ser interpretada como um modelo de risco para probabilidade de eventos.

4 Ajustando os Parâmetros do Modelo

Podemos ajustar β empiricamente usando um modelo de regressão logística em R:

```
glm(is.na(IDADEPAI) ~ IDADEMAE, family = binomial, data = df)
```

Isso permite estimar automaticamente o coeficiente β com base nos dados reais.

5 Conclusão

- Utilizamos uma função logística para modelar a ausência de IDADEPAI como uma função de IDADEMAE.
- A relação capturada reflete um mecanismo do tipo MAR (Missing at Random).
- O coeficiente β pode ser ajustado para controlar a intensidade do efeito.

6 Modelagem de Ausência de Dados e Avaliação de Métodos de Imputação

6.1 Introdução

O objetivo deste estudo é avaliar diferentes métodos de imputação para dados ausentes na variável IDADEPAI. Para isso, utilizamos simulações com três mecanismos de ausência de dados: MCAR (Missing Completely at Random), MAR (Missing at Random) e MNAR (Missing Not at Random). Os dados imputados são avaliados por meio de métricas estatísticas, comparando-os com os valores verdadeiros da população completa.

7 Cenários de Ausência de Dados

Para cada simulação, removemos uma proporção p dos dados de acordo com um dos seguintes mecanismos:

- **MCAR:** A ausência ocorre completamente ao acaso, sem relação com outras variáveis.
- **MAR:** A ausência está relacionada à idade da mãe (IDADEMAE), onde menores valores de IDADEMAE aumentam a probabilidade de IDADEPAI estar ausente. Esse mecanismo pode ser modelado como uma regressão logística:

$$P(\text{IDADEPAI} = \text{NA} \mid \text{IDADEMAE}) = \frac{1}{1 + e^{\beta_0 + \beta_1 \text{IDADEMAE}}} \quad (1)$$

- **MNAR:** A ausência depende diretamente do valor da própria variável IDADEPAI, sendo mais frequente para pais mais jovens:

$$P(\text{IDADEPAI} = \text{NA} \mid \text{IDADEPAI} < 30) > P(\text{IDADEPAI} = \text{NA} \mid \text{IDADEPAI} \geq 30) \quad (2)$$

8 Métodos de Imputação

Os métodos utilizados para preencher os valores ausentes incluem:

- **Casos completos:** Apenas os registros sem valores ausentes são utilizados na análise.
- **Imputação por Predictive Mean Matching (PMM):** Método baseado em vizinhos mais próximos que preserva a distribuição original.

9 Métricas de Avaliação

A qualidade das imputações é avaliada por meio das seguintes métricas:

9.1 Erro Quadrático Médio (RMSE)

Mede a diferença média entre os valores verdadeiros (y_i) e os imputados ($\hat{y}_i$):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3)$$

9.2 Viés Relativo (RB)

Compara a média dos valores imputados com a média dos valores verdadeiros:

$$RB = \frac{\bar{\hat{y}} - \bar{y}}{\bar{y}} \quad (4)$$

9.3 Proporção de Viés (PB)

Relaciona a diferença entre as médias imputadas e verdadeiras ao desvio padrão dos valores verdadeiros:

$$PB = \frac{\bar{\hat{y}} - \bar{y}}{s_y} \quad (5)$$

9.4 Erro Absoluto Médio (MAE)

Mede a magnitude média dos erros absolutos entre os valores imputados e os valores verdadeiros:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (6)$$

9.5 Erro Percentual Absoluto Médio (MAPE)

Expressa o erro absoluto médio como uma porcentagem dos valores verdadeiros:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \quad (7)$$

10 Conclusão

Através das simulações, analisamos o impacto de diferentes mecanismos de ausência de dados e métodos de imputação. A escolha do método de imputação ideal depende do mecanismo subjacente de ausência e do objetivo da análise. Em geral, métodos baseados em machine learning, como Random Forest, tendem a apresentar menor viés e erro quadrático médio.

10.1 Resultado Paraná 2022 CCA e MI (PMM)

Com base na análise dos erros associados às imputações nos cenários com **30% de missing**, podemos concluir que a confiabilidade dos resultados depende fortemente do mecanismo de dados ausentes. Para dados **MCAR** (*Missing Completely at Random*), onde a ausência ocorre de forma aleatória, o erro nos casos completos já é muito pequeno, indicando que a imputação pode não ser essencial. No entanto, a imputação pelo método **PMM** (*Predictive Mean Matching*) ainda apresenta um erro relativamente alto (RMSE 0.276, MAPE 0.881), sugerindo que pode não ser a melhor abordagem nesse caso.

Para o mecanismo **MAR** (*Missing At Random*), onde os dados ausentes dependem de outras variáveis observadas, a análise de casos completos gera um viés significativo, refletido em um RMSE elevado (1.202) e um erro percentual considerável (MAPE 3.835). A imputação com PMM reduz drasticamente esses erros (RMSE 0.243, MAPE 0.776), tornando os resultados mais próximos do verdadeiro parâmetro populacional. Assim, no cenário MAR, a imputação ainda é confiável e melhora significativamente a qualidade das estimativas.

Já no caso **MNAR** (*Missing Not at Random*), onde os valores ausentes dependem do próprio valor da variável analisada, o viés nos casos completos é ainda mais acentuado, com RMSE de 2.289 e MAPE de 7.307, o que indica que a análise sem imputação levaria a conclusões altamente distorcidas. A imputação com PMM reduz o erro, mas ainda mantém um RMSE relativamente alto (0.858) e um erro percentual considerável (MAPE 2.739), o que sugere

que os resultados podem não ser suficientemente confiáveis sem a aplicação de métodos mais robustos, como imputação baseada em *Random Forest*.

Portanto, para cenários com **30% de missing**, a imputação ainda pode ser considerada **confiável para MCAR e MAR**, pois os erros permanecem dentro de limites aceitáveis para muitas aplicações. No entanto, para MNAR, a incerteza permanece alta, o que exige cautela na interpretação dos resultados e possivelmente o uso de técnicas mais avançadas. Se o objetivo for obter um erro menor que 1%, esses cenários podem não ser suficientemente confiáveis, mas se um erro de até 5% for aceitável, os resultados para MCAR e MAR ainda são úteis.