

Para as Simulações - TEX

Com base em: <https://stefvanbuuren.name/fimd/sec-evaluation.html>

- Medida que será imputada Q
- Vamos partir dos dados completos do Paraná (ou escolhe uma UF/Ano que tenha o menor percentual de missing)
- Para os dados completos se calcula o *true value* Q
- Podemos depois avaliar se iremos gerar uma população simulada

```
#install.packages("truncnorm")
library(truncnorm)

create.data <- function(beta = 1, sigma2 = 1, n = 50,
                        run = 1) {
  set.seed(seed = 12345)
  #x <- rnorm(n)
  x <- ceiling(rtruncnorm(n, a=12, b=45, mean=20, sd=10))
  #y <- beta * x + rnorm(n, sd = sqrt(sigma2))
  y <- ceiling(rtruncnorm(n, a=12, b=85, mean=40, sd=25))
  data.frame(idade_mae = x, idade_pai = y)
}

dado.completo <- create.data(n=100)

hist(dado.completo$idade_mae)
hist(dado.completo$idade_pai)

boxplot(dado.completo$idade_mae,dado.completo$idade_pai)
```

Métricas

Viés bruto (RB) e viés percentual (PB). O viés bruto da estimativa $\bar{Q}$ é definido como a diferença entre o valor esperado da estimativa eo verdadeiro valor.

$$RB = E(\bar{Q}) - Q$$

O RB deve estar próximo de zero. O viés também pode ser expresso como viés percentual:

$$PB = 100 \times \left| \frac{(E(\bar{Q}) - Q)}{Q} \right|$$

Para um desempenho aceitável, utilizamos um limite superior para o PB de 5%. (Demirtas, Freels e Yucel 2008)

Tradução para Português

Erro quadrático médio (RMSE). O

$$RMSE = \sqrt{(E(\bar{Q}) - Q)^2}$$

é um compromisso entre viés e variância, e avalia $\bar{Q}$ em termos de precisão e exatidão.

Processos sugeridos de simulação

Amostragem apenas: Os passos básicos da simulação são: escolher Q , coletar amostras $Y(s)$, ajustar o modelo/imputação de dados completos, estimar $\hat{Q}(s)$ e $U(s)$ e calcular os resultados agregados sobre s .

Amostragem e mecanismo de dados ausentes combinados: Os passos básicos da simulação são: escolher Q , coletar amostras $Y(s)$, gerar dados incompletos $Y(s, t)_{obs}$, imputar, estimar $\hat{Q}(s, t)$ e $T(s, t)$ e calcular os resultados agregados sobre s e t .

Mecanismo de dados ausentes apenas Os passos básicos da simulação são: escolher $(\hat{Q}, U)$, gerar dados incompletos $Y(t)_{obs}$, imputar, estimar $(\bar{Q}, \bar{U})(t)$ e $B(t)$ e calcular os resultados agregados sobre t .

Do artigo <https://pmc.ncbi.nlm.nih.gov/articles/PMC8426774/>

Viés Absoluto ($|\text{viés}|$) e Erro Quadrático Médio (RMSE) de IM (imputação múltipla) medido sob as suposições de Dados Ausentes Com-

pletamente ao Acaso (MCAR), Dados Ausentes ao Acaso (MAR) e Não Ausentes ao Acaso (NMAR).

Viés Absoluto

O viés absoluto é uma medida da precisão de um estimador, definido como a média das diferenças absolutas entre os valores estimados e os valores verdadeiros. A fórmula para o viés absoluto é:

$$|B| = \frac{1}{n} \sum_{i=1}^n |\hat{Q}_i - Q_i|$$

onde $\hat{Q}_i$ é o valor estimado e Q_i é o valor verdadeiro e n é a quantidade de amostras geradas (quantas vezes a amostragem foi repetida).

Erro Quadrático Médio (RMSE)

O erro quadrático médio é uma medida que quantifica a diferença entre os valores previstos e os valores observados, calculado como a raiz quadrada da média dos quadrados das diferenças:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{Q}_i - Q_i)^2}$$

Considerações sobre MCAR, MAR e NMAR

- **MCAR (Dados Ausentes Completamente ao Acaso):** As observações ausentes não estão relacionadas a nenhuma variável observada ou não observada. Isso implica que o viés absoluto e o RMSE podem ser minimizados, pois a ausência de dados não introduz viés.
- **MAR (Dados Ausentes ao Acaso):** As observações ausentes podem estar relacionadas a variáveis observadas, mas não às variáveis ausentes. O viés absoluto pode ser maior do que em MCAR, e o RMSE pode ser afetado dependendo da natureza das variáveis observadas.
- **NMAR (Não Ausentes ao Acaso):** As observações ausentes estão relacionadas às próprias variáveis ausentes. Isso pode resultar em um viés absoluto significativo e um RMSE elevado, pois a ausência de dados pode introduzir um viés sistemático nas estimativas.

Adaptando a ideia

- Gerar um padrão univariado de dados ausentes
- Remover algumas observações para a variável Idade do Pai no conjunto de dados-completos, enquanto todas as outras variáveis são mantidas mantidas.
- Para MCAR: diferentes quantidades de observações para a variável (Idade do Pai) deletadas aleatoriamente - considerar 0%, 20%, 40%, 60% e 80% de dados ausentes.
- Para MAR : ordenar/classificar os dados completos de acordo com uma das variáveis completamente observadas (Idade da Mãe, variável x) e excluir os valores mais baixos (ou mais altos) dos casos da Idade do Pai em diferentes porcentagens dos valores ausentes para gerar o mecanismo MAR.
- Para o mecanismo NMAR: ordenar/classificar os dados completos pela própria variável ausente (Idade do Pai) e os valores da Idade do Pai são excluídos em cinco taxas diferentes
- Fazer isso separadamente e independentemente para criar conjuntos de dados incompletos para os três mecanismos de ausência.

Acho que pode valer a pena você pensar em gerar para diferentes mecanismos

Com ajuda, tem-se os códigos para gerar os dados

```
# Definindo a semente para reprodutibilidade
set.seed(123)

# Instalando e carregando o pacote necessário
# install.packages("truncnorm")
library(truncnorm)

create.data <- function(beta = 1, sigma2 = 1, n = 50, run = 1) {
  set.seed(seed = 123)
  x <- ceiling(rtruncnorm(n, a=12, b=45, mean=20, sd=10))
  y <- ceiling(rtruncnorm(n, a=12, b=85, mean=40, sd=25))
  data.frame(Idade_Mae = x, Idade_Pai = y)
```

```

}

dados <- create.data(n=100)

# Função para gerar dados MAR
gerar_mar <- function(dados, porcentagem) {
  # Ordenando os dados pela Idade da Mãe
  dados_ordenados <- dados[order(dados$Idade_Mae), ]

  # Calculando o número de observações a serem removidas
  n_remove <- floor(nrow(dados_ordenados) * porcentagem)

  # Removendo os n_remove menores valores da Idade do Pai
  dados_ordenados$Idade_Pai[1:n_remove] <- NA

  return(dados_ordenados)
}

# Função para gerar dados NMAR
gerar_nmar <- function(dados, porcentagem) {
  # Ordenando os dados pela Idade do Pai
  dados_ordenados <- dados[order(dados$Idade_Pai), ]

  # Calculando o número de observações a serem removidas
  n_remove <- floor(nrow(dados_ordenados) * porcentagem)

  # Removendo os n_remove maiores valores da Idade do Pai
  dados_ordenados$Idade_Pai[(nrow(dados_ordenados) - n_remove + 1):nrow(dados_ordenados)] <- NA

  return(dados_ordenados)
}

# Função para gerar dados MCAR
gerar_mcar <- function(dados, porcentagem) {
  # Copiando os dados para não alterar o original
  dados_mcar <- dados

  # Calculando o número de observações a serem removidas
  n_remove <- floor(nrow(dados_mcar) * porcentagem)

```

```

# Selecionando aleatoriamente índices para remover
indices_remove <- sample(1:nrow(dados_mcar), n_remove)

# Removendo os valores da Idade do Pai nos índices selecionados
dados_mcar$Idade_Pai[indices_remove] <- NA

return(dados_mcar)
}

# Aplicando a função para diferentes porcentagens de dados ausentes para MAR
porcentagens_mar <- c(0.2, 0.4, 0.6, 0.8) # Porcentagens de dados ausentes para MAR
resultados_mar <- setNames(lapply(porcentagens_mar, function(p) gerar_mar(dados, p)),
                           paste0("MAR_", porcentagens_mar * 100))

# Aplicando a função para diferentes porcentagens de dados ausentes para NMAR
porcentagens_nmar <- c(0.2, 0.4, 0.6, 0.8) # Porcentagens de dados ausentes para NMAR
resultados_nmar <- setNames(lapply(porcentagens_nmar, function(p) gerar_nmar(dados, p)),
                           paste0("NMAR_", porcentagens_nmar * 100))

# Aplicando a função para diferentes porcentagens de dados ausentes para MCAR
porcentagens_mcar <- c(0.0, 0.2, 0.4, 0.6, 0.8) # Porcentagens de dados ausentes para MCAR
resultados_mcar <- setNames(lapply(porcentagens_mcar, function(p) gerar_mcar(dados, p)),
                           paste0("MCAR_", porcentagens_mcar * 100))

View(resultados_mar$MAR_20)
View(resultados_mcar$MCAR_20)
View(resultados_nmar$NMAR_20)

```

As simulações para MAR com $p=0,2; 0,4; 0,6; 0,8$

Códigos feitos com ajuda de ferramentas (precisa ser verificado e modificado para os demais mecanismos!)

```

# Definindo a semente para reprodutibilidade
set.seed(123)

# Instalando e carregando os pacotes necessários
# install.packages("truncnorm")
# install.packages("dplyr")

```

```

# install.packages("knitr")
library(truncnorm)
library(dplyr)
library(knitr)

# Função para criar dados com Idade da Mãe e Idade do Pai -- Aqui vc pode colocar os
create.data <- function(n = 50) {
  x <- ceiling(rtruncnorm(n, a=12, b=45, mean=20, sd=10)) # Idade da Mãe
  y <- ceiling(rtruncnorm(n, a=12, b=85, mean=40, sd=25)) # Idade do Pai
  data.frame(Idade_Mae = x, Idade_Pai = y)
}

# Função para gerar dados MAR com percentual de missing
gerar_mar <- function(dados, percentagem) {
  dados_ordenados <- dados %>% arrange(Idade_Mae)
  n_remove <- floor(nrow(dados_ordenados) * percentagem)
  dados_ordenados$Idade_Pai[1:n_remove] <- NA
  return(dados_ordenados)
}

# Função para imputar pela média
imputar_media <- function(dados) {
  media_idade_pai <- mean(dados$Idade_Pai, na.rm = TRUE) # Calcula a média ignorando
  dados$Idade_Pai[is.na(dados$Idade_Pai)] <- media_idade_pai # Imputa a média nos NA
  return(dados)
}

# Percentuais de missing a serem testados
percentuais_missing <- c(0.2, 0.4, 0.6, 0.8)
n_simulacoes <- 500

# Tabela para armazenar os resultados
resultados_tabela <- tibble(
  Percentual_Missing = numeric(),
  Media_Idade_Pai_Imputada = numeric(),
  Media_RB = numeric(),
  Media_RMSE = numeric()
)

# Simulação para cada percentual de missing

```

```

for (porcentagem in percentuais_missing) {

  medias_idades_imputadas <- numeric(n_simulacoes) # Vetor para armazenar as médias
  todas_idades_pai <- numeric(n_simulacoes)        # Vetor para armazenar as idades

  for (i in seq_len(n_simulacoes)) {
    dados <- create.data(n = 100)                  # Cria os dados
    dados_mar <- gerar_mar(dados, porcentagem)      # Gera dados MAR com o percentual
    dados_imputados <- imputar_media(dados_mar)      # Imputa pela média

    medias_idades_imputadas[i] <- mean(dados_imputados$Idade_Pai) # Armazena a média
    todas_idades_pai[i] <- mean(dados$Idade_Pai)          # Armazena a média d
  }

  # Resultado final para o percentual atual: média das idades do pai imputadas em cada
  media_final <- mean(medias_idades_imputadas)

  # Resultados das métricas médias
  mean_rb <- mean(medias_idades_imputadas - todas_idades_pai) # Viés Bruto médio
  mean_rmse <- sqrt(mean((medias_idades_imputadas - todas_idades_pai)^2)) # RMSE

  # Armazenando os resultados na tabela usando dplyr
  resultados_tabela <- resultados_tabela %>%
    add_row(
      Percentual_Missing = porcentagem * 100,
      Media_Idade_Pai_Imputada = media_final,
      Media_RB = mean_rb,
      Media_RMSE = mean_rmse
    )
}

# Exibindo a tabela final com os resultados usando kable
resultados_tabela %>%
  kable(caption = "Resultados da Simulação de Dados com Missingness")

```

Para MCAR

```

# Definindo a semente para reprodutibilidade

```



```

set.seed(123)

# Instalando e carregando os pacotes necessários
# install.packages("truncnorm")
# install.packages("dplyr")
# install.packages("knitr")
library(truncnorm)
library(dplyr)
library(knitr)

# Função para criar dados com Idade da Mãe e Idade do Pai
create.data <- function(n = 50) {
  x <- ceiling(rtruncnorm(n, a=12, b=45, mean=20, sd=10)) # Idade da Mãe
  y <- ceiling(rtruncnorm(n, a=12, b=85, mean=40, sd=25)) # Idade do Pai
  data.frame(Idade_Mae = x, Idade_Pai = y)
}

# Função para gerar dados MCAR com percentual de missing
gerar_mcar <- function(dados, porcentagem) {
  n_remove <- floor(nrow(dados) * porcentagem)
  indices_remove <- sample(1:nrow(dados), n_remove) # Seleciona aleatoriamente os
  dados$Idade_Pai[indices_remove] <- NA # Remove os valores da Idade do Pai nos índ
  return(dados)
}

# Função para imputar pela média
imputar_media <- function(dados) {
  media_idade_pai <- mean(dados$Idade_Pai, na.rm = TRUE) # Calcula a média ignorando
  dados$Idade_Pai[is.na(dados$Idade_Pai)] <- media_idade_pai # Imputa a média nos NA
  return(dados)
}

# Percentuais de missing a serem testados
percentuais_missing <- c(0, 0.2, 0.4, 0.6, 0.8)
n_simulacoes <- 500

# Tabela para armazenar os resultados
resultados_tabela <- tibble(
  Percentual_Missing = numeric(),
  Media_Idade_Pai_Imputada = numeric(),

```

```

    Media_RB = numeric(),
    Media_RMSE = numeric()
  )

# Simulação para cada percentual de missing
for (porcentagem in percentuais_missing) {

  medias_idades_imputadas <- numeric(n_simulacoes) # Vetor para armazenar as médias
  todas_idades_pai <- numeric(n_simulacoes)        # Vetor para armazenar as idades

  for (i in seq_len(n_simulacoes)) {
    dados <- create.data(n = 100)                  # Cria os dados
    dados_mcar <- gerar_mcar(dados, porcentagem)    # Gera dados MCAR com o per
    dados_imputados <- imputar_media(dados_mcar) # Imputa pela média

    medias_idades_imputadas[i] <- mean(dados_imputados$Idade_Pai) # Armazena a média
    todas_idades_pai[i] <- mean(dados$Idade_Pai)                  # Armazena a média d
  }

  # Resultado final para o percentual atual: média das idades do pai imputadas em cad
  media_final <- mean(medias_idades_imputadas)

  # Resultados das métricas médias
  mean_rb <- mean(medias_idades_imputadas - todas_idades_pai) # Viés Bruto médio
  mean_rmse <- sqrt(mean((medias_idades_imputadas - todas_idades_pai)^2)) # RMSE

  # Armazenando os resultados na tabela usando dplyr
  resultados_tabela <- resultados_tabela %>%
    add_row(
      Percentual_Missing = porcentagem * 100,
      Media_Idade_Pai_Imputada = media_final,
      Media_RB = mean_rb,
      Media_RMSE = mean_rmse
    )
}

# Exibindo a tabela final com os resultados usando kable
resultados_tabela %>%
  kable(caption = "Resultados da Simulação de Dados com Missingness (MCAR)")

```

Para NMAR

```
# Definindo a semente para reprodutibilidade
set.seed(123)

# Instalando e carregando os pacotes necessários
# install.packages("truncnorm")
# install.packages("dplyr")
# install.packages("knitr")
library(truncnorm)
library(dplyr)
library(knitr)

# Função para criar dados com Idade da Mãe e Idade do Pai
create.data <- function(n = 50) {
  x <- ceiling(rtruncnorm(n, a=12, b=45, mean=20, sd=10)) # Idade da Mãe
  y <- ceiling(rtruncnorm(n, a=12, b=85, mean=40, sd=25)) # Idade do Pai
  data.frame(Idade_Mae = x, Idade_Pai = y)
}

# Função para gerar dados NMAR com percentual de missing
gerar_nmar <- function(dados, porcentagem) {
  dados_ordenados <- dados %>% arrange(Idade_Pai) # Ordena pela Idade do Pai
  n_remove <- floor(nrow(dados_ordenados) * porcentagem)
  dados_ordenados$Idade_Pai[(nrow(dados_ordenados) - n_remove + 1):nrow(dados_ordenados)] <- NA
  return(dados_ordenados)
}

# Função para imputar pela média
imputar_media <- function(dados) {
  media_idade_pai <- mean(dados$Idade_Pai, na.rm = TRUE) # Calcula a média ignorando NA
  dados$Idade_Pai[is.na(dados$Idade_Pai)] <- media_idade_pai # Imputa a média nos NA
  return(dados)
}

# Percentuais de missing a serem testados
percentuais_missing <- c(0.2, 0.4, 0.6, 0.8)
n_simulacoes <- 500

# Tabela para armazenar os resultados
```

```

resultados_tabela <- tibble(
  Percentual_Missing = numeric(),
  Media_Idade_Pai_Imputada = numeric(),
  Media_RB = numeric(),
  Media_RMSE = numeric()
)

# Simulação para cada percentual de missing
for (porcentagem in percentuais_missing) {

  medias_idades_imputadas <- numeric(n_simulacoes) # Vetor para armazenar as médias
  todas_idades_pai <- numeric(n_simulacoes)        # Vetor para armazenar as idades

  for (i in seq_len(n_simulacoes)) {
    dados <- create.data(n = 100)                  # Cria os dados
    dados_nmar <- gerar_nmar(dados, porcentagem)    # Gera dados NMAR com o per
    dados_imputados <- imputar_media(dados_nmar) # Imputa pela média

    medias_idades_imputadas[i] <- mean(dados_imputados$Idade_Pai) # Armazena a média
    todas_idades_pai[i] <- mean(dados$Idade_Pai)                  # Armazena a média d
  }

  # Resultado final para o percentual atual: média das idades do pai imputadas em cad
  media_final <- mean(medias_idades_imputadas)

  # Resultados das métricas médias
  mean_rb <- mean(medias_idades_imputadas - todas_idades_pai) # Viés Bruto médio
  mean_rmse <- sqrt(mean((medias_idades_imputadas - todas_idades_pai)^2)) # RMSE

  # Armazenando os resultados na tabela usando dplyr
  resultados_tabela <- resultados_tabela %>%
    add_row(
      Percentual_Missing = porcentagem * 100,
      Media_Idade_Pai_Imputada = media_final,
      Media_RB = mean_rb,
      Media_RMSE = mean_rmse
    )
}

# Exibindo a tabela final com os resultados usando kable

```

```
resultados_tabela %>%  
  kable(caption = "Resultados da Simulação de Dados com Missingness (NMAR)")
```

Claro! Um organograma pode ajudar a visualizar o processo de simulação para cada mecanismo de dados faltantes (MCAR, MAR e NMAR). Abaixo, descrevo como seria o organograma, e em seguida, forneço uma representação textual que você pode usar como referência para criar um gráfico visual.

Organograma do Processo de Simulação

1. Início

- Definir a semente para reprodutibilidade.

2. Criar Dados

- Gerar um conjunto de dados com duas variáveis: Idade da Mãe e Idade do Pai.

3. Para Cada Percentual de Missing (20%, 40%, 60%, 80%)

- **Simulação:**
 - Repetir o processo para um número definido de simulações (ex: 500).
 - **Gerar Dados Faltantes:**
 - * **MCAR:** Remover aleatoriamente uma porcentagem dos valores da Idade do Pai.
 - * **MAR:** Ordenar os dados pela Idade da Mãe e remover os menores valores da Idade do Pai.
 - * **NMAR:** Ordenar os dados pela Idade do Pai e remover os maiores valores.
 - **Imputação:**
 - * Imputar os valores faltantes pela média da Idade do Pai.
 - **Calcular Métricas:**
 - * Calcular a média das idades imputadas.
 - * Calcular o viés bruto (RB).
 - * Calcular o erro quadrático médio (RMSE).


4. Armazenar Resultados


- Armazenar as médias das idades imputadas, RB e RMSE em uma tabela.

5. Exibir Resultados

- Mostrar a tabela com os resultados formatados.

6. Fim





Organograma em RMD

```

# Carregar pacotes necessários
#install.packages("DiagrammeR")
library(DiagrammeR)

grViz("
digraph process {
  graph [layout = dot, rankdir = TB]

  node [shape = rectangle, style = filled, fillcolor = lightblue]

  start [label = 'Início', shape = ellipse]
  create_data [label = 'Dados Completos']
  for_each_percentage [label = 'Diferentes percentuais de dados faltantes']

  mcar [label = 'Gerar MCAR']
  mar [label = 'Gerar MAR']
  nmar [label = 'Gerar NMAR']

  imputar [label = 'Diferentes métodos de imputação']
  calcular_metricas [label = 'Calcular Métricas (RB, RMSE)']
  store_results [label = 'Armazenar Resultados']
  end [label = 'Fim', shape = ellipse]

  start -> create_data
  create_data -> for_each_percentage
  for_each_percentage -> mcar

```

```

for_each_percentage -> mar
for_each_percentage -> nmar

mcar -> imputar
mar -> imputar
nmar -> imputar

imputar -> calcular_metricas
calcular_metricas -> store_results
store_results -> end
}
")

```

Organograma no latex

```

\begin{tikzpicture}[
    % Definindo estilos para os nós
    node style/.style={rectangle, rounded corners, draw=black, minimum width=2cm, m
    startstop/.style={ellipse, draw=black},
    process/.style={rectangle, draw=black},
    arrow/.style={thick,->,>=stealth}
]

% Nós do organograma
\node[startstop] (start) {Início};
\node[process] (create) [below of=start] {Dados Completos};
\node[process] (percent) [below of=create] {Diferentes percentuais de \textit{missing}}

% Nós de decisão alinhados lado a lado
\node[process] (mcar) [below of=percent, xshift=-3cm] {Gerar MCAR};
\node[process] (mar) [below of=percent] {Gerar MAR};
\node[process] (nmar) [below of=percent, xshift=3cm] {Gerar NMAR};

\node[process] (impute) [below of=mcar, yshift=-1cm, xshift=3cm] {Diferentes métodos
\node[process] (metrics) [below of=impute] {Calcular Métricas (RB, RMSE)};
\node[process] (store) [below of=metrics] {Armazenar Resultados};
\node[startstop] (end) [below of=store] {Fim};

% Conectando os nós

```



```

\draw[arrow] (start) -- (create);
\draw[arrow] (create) -- (percent);
\draw[arrow] (percent) -- (mcar);
\draw[arrow] (percent) -- (mar);
\draw[arrow] (percent) -- (nmar);
\draw[arrow] (mar) -- (impute);
\draw[arrow] (mcar) -- (impute);
\draw[arrow] (nmar) -- (impute);
\draw[arrow] (impute) -- (metrics);
\draw[arrow] (metrics) -- (store);
\draw[arrow] (store) -- (end);

\end{tikzpicture}

```

Referências

<https://stefvanbuuren.name/fimd/sec-evaluation.html>
<https://www.scielo.br/j/rbmet/a/RYYKg5VtRXXpSc9q3DRKPns/>
https://www.youtube.com/watch?v=__pJX2SFoFtY
<https://analisemacro.com.br/econometria-e-machine-learning/mae-rmse-acc-f1-roc-r2-avaliacao-de-desempenho-de-modelos-preditivos/>
[https://edisciplinas.usp.br/pluginfile.php/3043641/mod_resource/content/1/PROPRIEDADES DOS ESTIMADORES.pdf](https://edisciplinas.usp.br/pluginfile.php/3043641/mod_resource/content/1/PROPRIEDADES_DOS_ESTIMADORES.pdf)
https://pt.wikipedia.org/wiki/Erro_quadrático_médio
<https://mariofilho.com/rmse-raiz-do-erro-quadratico-medio-em-machine-learning/>
<https://pt.linkedin.com/advice/0/how-can-you-interpret-mean-squared-error-your-predictive-iifdf?lang=pt>

